

AIDC 项目验收综合测试报告

1024 卡 H100 集群项目验收

报告编号 GPU**TEST**-2026-04-008

交付客户 某 Top3 智算中心运营方(脱敏)

报告日期 2026-04-22

版本 v1.0

出具方 北京品晰科技有限公司

保密说明

内部资料 · 限受文方使用。本报告含客户机密信息,未经书面授权不得复制 / 转发 / 公开。原始 telemetry 数据按 NDA 条款约定 30 日内销毁,仅保留指标摘要供合规备查。

01

执行摘要

合同 KPI 项	一次达标	整改后达标	未达标
14	13	1	0

✓ 整体结论

14 项合同 KPI 中 13 项一次达标,1 项(NCCL 多机扩展效率)经厂家整改后复测达标。整体满足验收条件,建议签收。

项目概况

项目名称	某 Top3 智算中心一期
集群规模	1024 张 GPU · 128 节点
GPU 卡型	NVIDIA H100 SXM5 80GB
网络类型	InfiniBand NDR400 · Fat-tree 1:1
测试周期	16 天 (2026-04-06 至 2026-04-22)

测试范围(三支柱 × 两层级)

本次验收按合同 SOW 执行全部 6 格测试用例。

	单机	集群
稳定性	DCGM Diag · gpu-burn · cuda_memtest	168h 真实负载 soak · 故障注入
性能	算力 vs 标称 · HBM/PCIe/NVLink	NCCL 多机扩展 · e2e 时延
模型质量	单卡推理精度 · 量化	多机训练收敛 · 长上下文

02

合同 KPI 逐项对账

下表为合同 KPI 与实测值的逐项对照。状态分为「通过 / 整改后达标 / 未达标」三档。未达标项详细分析见 §05。

KPI	合同要求	实测值	状态
单卡 FP16 算力 (TFLOPS)	≥ 950	973 (中位)	通过
HBM 带宽 (GB/s)	≥ 3200	3287 (中位)	通过
PCIe Gen5 实测 (GB/s)	≥ 50	53.2	通过
NVLink 对称性偏差	< 5%	2.8%	通过
168h soak 训练任务 NaN 中断	0 次	0 次	通过
168h soak XID 事件总数	≤ 5	3	通过
IB 链路误码率 (BER)	< 1e-12	3.2e-14	通过
NCCL all-reduce 8 节点扩展效率	≥ 92%	94.1%	通过
NCCL all-reduce 32 节点扩展效率	≥ 88%	89.3%	整改后
Llama2-70B 千卡训练 step 时间 (ms)	≤ 4500	4280	通过
故障注入 (拔卡) 恢复时间	≤ 5 min	3 min 12 s	通过
MMLU 分数 (Llama2-70B)	≥ 76.0	76.2	通过
多机训练输出语义余弦	≥ 0.997	0.998	通过
RAS 事件 (HBM ECC)	总计 ≤ 10	4	通过

03

稳定性 · 单机与集群

单机硬件健康

测试项:DCGM Diag Level 3 · gpu-burn 8h · cuda_memtest 全 HBM · IPMI 整机风冷

检测维度	状态	实测摘要
HBM ECC	通过	全部节点 ECC 计数 < 1/天/卡,符合健康指标
温度 / 降频	通过	群均 78℃,无降频事件
PSU / 风扇	通过	全部 PSU 输出稳定,无电压抖动告警

集群级 168h soak

执行 Llama2-70B 千卡训练 + Stable Diffusion 推理混合,持续 168 小时 (2026-04-12 至 2026-04-19)。

指标	状态	实测
训练任务 NaN 中断	通过	0 次 NaN / loss spike 中断
XID 事件总数	通过	3 次 XID(均为 XID 13,可恢复)
链路抖动 / Flap	通过	全程无链路 Flap

04

性能 · 单机与集群

单机性能

指标	标称	实测中位	状态
FP16 算力 (TFLOPS)	989	973	通过
HBM 带宽 (GB/s)	3350	3287	通过

集群性能 · NCCL 多机扩展

节点数	8	16	32	N
扩展效率	94.1%	92.4%	89.3%	84.6% (128 节点)

✓ 训练吞吐

Llama2-70B 千卡训练 step 时间 4280 ms,达标。

05

不达标项与整改

本次验收识别 1 项不达标 / 待关注项,按风险优先级列出,附定位证据与建议处置路径。

优先级	资产	问题	建议处置
黄	节点 N-049 / 50 / 51 / 52(rack-12)	32 节点 NCCL 实测扩展效率初次为 84.7%,低于合同要求 88%;定位为 该 rack 内 4 节点的 NCCL_IB_HCA 选择不一致	厂家同步统一 NCCL 环境变量;复测达标 89.3%。

A

附录 · 工具与版本

本报告中使用的工具与版本如下,客户可独立复核。所有原始执行日志保存在交付的 **telemetry** 数据包中,SHA256 校验值见末尾。

工具	版本	来源	用途
NVIDIA Field Diag	v3-2024Q4	厂商官方	硬件级现场诊断
NVIDIA DCGM Diag	3.3.5	厂商官方	数据中心诊断 (Level 3)
gpu-burn	1.1+gputest	开源	单机满载压测 8h
cuda_memtest	1.2.4	开源	HBM 全 bit 扫描
nccl-tests	2.21.5	厂商官方	多机 NCCL 扩展
ib_send_bw / ibdiagnet	perftest 4.5	开源	IB 链路误码与带宽
DCGM Exporter + Prometheus	3.3.5 / 2.50	厂商 + 开源	168h telemetry
Llama2-70B harness	Megatron 24.04	自研	真实负载 soak
lm-eval-harness	0.4.4	开源	MMLU 评测

原始数据索引

全部 **telemetry** / NCCL 跑分 / DCGM 日志按节点归档于交付数据包中,SHA256 见 **MANIFEST.sha256**。客户可在合同 NDA 期限内执行独立复核。

复测条款

乙方完成整改后,我方依据本 SOW 对整改项执行复测,出具复测确认函,作为最终签收依据。复测费用按合同附件 B 第 4 条计。

验收签字页

报告编号: GPUTEST-2026-04-008

本人确认已收到由 北京品晰科技有限公司 出具的上述测试报告,并对报告中 列示的测试方法、KPI 对账结果、不达标项及整改建议予以审阅。报告原文与原始 **telemetry** 数据按 NDA 约定保密。

甲方 某 **Top3** 智算中心运营方(脱敏)

乙方 北京品晰科技有限公司

代表: (客户基础设施负责人)

代表: (GPUTest 项目负责人)

签字: _____

签字: _____

日期: _____

日期: _____