

模型质量评测报告

Qwen2-72B 在昇腾 910B 上的迁移评估

报告编号 GPU**TEST**-2026-04-006

交付客户 某金融机构 AI 平台(脱敏)

报告日期 2026-04-15

版本 v1.0

出具方 北京品晰科技有限公司

保密说明

内部资料 · 限受文方使用。本报告含客户机密信息,未经书面授权不得复制 / 转发 / 公开。原始 telemetry 数据按 NDA 条款约定 30 日内销毁,仅保留指标摘要供合规备查。

01

评测摘要

评测对象

模型	Qwen2-72B-Chat
参考硬件	NVIDIA H100 FP32
目标硬件	昇腾 910B
量化精度	FP16 · FP8 · INT8 · INT4

✓ 整体结论

目标硬件输出与 H100 参考语义余弦 0.997, MMLU Δ -0.3, 达到合同迁移阈值。建议采用 FP16 / INT8 量化方案。

关键指标

语义余弦相似度

BLEU

NIAH 通过率

0.997

92.4

100%

02

标准 benchmark 对比

下表为目标硬件与参考硬件在公开标准 benchmark 上的分数对比。Δ 列为目标 - 参考。绿色表示 $\Delta \geq -0.5$ (可视为同档),黄色表示退化在 0.5-1.5 之间,红色表示退化超过 1.5。

测试项	参考	目标	Δ
MMLU (5-shot)	76.2	75.9	-0.29999999999999716
CMMLU (5-shot)	81.4	81	-0.4000000000000057
CEval (5-shot)	80.7	80.5	-0.20000000000000284
GSM8K (8-shot)	91.5	91	-0.5
HumanEval (pass@1)	67.4	66.8	-0.6000000000000085
MMBench (v1.1)	78.9	78.4	-0.5

03

量化精度退化

MMLU 分数随精度变化

从 FP16 → FP8 → INT8 → INT4 各档对照 MMLU 实测分数与退化幅度。



i 量化推荐

FP16 与 FP8 量化退化 < 1 分,可直接生产使用。INT8 退化 1.1 分,适合大规模推理服务(吞吐优先)。INT4 退化 2.8 分,不建议用于高质量场景。

04

推理输出 diff 分析

测试方法

测试集合:12000 条 prompt(来源:客户提供风控场景 prompt) 对比方式:目标硬件输出 vs 参考硬件 FP32 输出

关键数据

指标	实测	基准
语义余弦相似度	0.997	≥ 0.99
BLEU	92.4	≥ 90
Logits L2 距离 (中位)	0.012	-
输出长度偏离	1.8%	$< 5\%$

✓ diff 结论

12k 条业务 prompt 中,98.4% 输出与 H100 参考几乎一致(余弦 ≥ 0.99)。Δ 主要集中在长尾问答与数学题,均在可接受范围。

05

长上下文质量 · NIAH

Needle-In-A-Haystack(NIAH)测试:在不同上下文长度(横轴)与不同插入深度(纵轴)下, 模型回忆 **needle** 的成功率。绿色 ≥ 0.95 ,黄色介于 0.85 至 0.95,红色低于 0.85。

Depth↓ / Length→	cells	0%
1	1	1
1	1	1
20%	1	1
1	1	0.98
0.96	40%	1
1	1	0.99
0.96	0.92	60%
1	1	0.99
0.97	0.94	0.9
80%	1	1
0.98	0.96	0.92
0.88	100%	1
1	0.97	0.95
0.9	0.85	

i

长上下文结论

在 4k-32k 全段长度均通过 NIAH 测试。RULER 综合分 89.2,与 H100 参考(89.5)基本一致。

06

结论与迁移建议

通过条件

- 标准 benchmark 全部 6 项通过, Δ 中位 -0.3
- 12k 条业务 prompt diff 语义余弦 0.997, 达标
- FP16 / FP8 量化方案在 MMLU 上退化 < 1 分, 可上生产
- 长上下文 NIAH 4k-32k 全段通过

待优化项

- INT4 量化在 MMLU 退化 2.8 分, 不建议用于高质量场景
- 32k 长度下 100% depth 通过率为 0.85, 接近阈值, 建议监控

迁移建议

i 迁移评估

迁移评估通过。推荐生产部署使用 FP16 + 选用 INT8 用于高吞吐推理服务。客户业务 prompt 在目标硬件上输出与 H100 参考保持高一致性, 符合合同迁移条款。

A

附录 · 工具与版本

本报告中使用的工具与版本如下,客户可独立复核。所有原始执行日志保存在交付的 **telemetry** 数据包中,SHA256 校验值见末尾。

工具	版本	来源	用途
lm-eval-harness	0.4.4	开源	标准 benchmark 套件
OpenCompass	0.2.6	开源	中文 / 多模态评测
GPUTest diff harness	0.3	自研	12k prompt 输出对比 + 余弦 / BLEU / L2
RULER	1.0	开源	长上下文质量综合评估
NeedleInAHaystack	1.5	开源	NIAH 长上下文回忆测试
Ascend CANN + MindIE	8.0.RC2	厂商官方	昇腾 910B 推理引擎

复核说明

全部 prompt / 输出 / logits / 指标计算均保留在交付数据包中。 客户可使用我方提供的 **evaluation** 脚本在自有环境复跑,结果应在 ± 0.5 之内。

北京品晰科技有限公司 · sales@gputest.cn · gputest.cn